Forelesning 1

tirsdag 13. januar 2026 09:22

Maskinlæring for økonomer

Vurdering
- Prosjektarbeid 40%
- Muntlig eksamen 60%

} Se kursets hjemmeside.

"Intelligens"

Evner til å prosessere informasjon, som vil gi kunnskap til å ta beslutninger i fremtiden

(En av mange mulige definisjoner)

→ "AI" er at vi "gir" datamaskiner muligheten til å gjøre det samme. Dette gjøres vha. DATA.

Vårt mål i kurset

[Lære datamaskiner hvordan lære en oppgave fra innsamlet data]

Intro. til Maskinlæring - del 1

Nødvendig lineær algebra

VEKTOR

En vektor er en ordnet liste av tall som kan representere datapunkter i et flerdimensjonalt rom.

En vektor $\mathbf{x}$ i n dimensjoner:

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

x_i, $i = 1, 2, \dots, n$ er komponentene til vektoren.

MATRISE

Rektangulær tabell av tall (symboler), og brukes ofte til å representere data eller transformasjoner.

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix}$$

- Dimensjon: $m \times n$
- Horisontale = rader (m)
- vertikale = kolonner (n)

Eksempel:

ofte trenger vi både matriser og vektorer for å presentere data.

Forutsi lønn basert på utdanning (år) og erfaring (år).

Da kan man skrive data som

$$X = \begin{pmatrix} 12 & 3 \\ 16 & 5 \\ 14 & 2 \\ 10 & 0 \\ \vdots & \vdots \end{pmatrix} \qquad Y = \begin{pmatrix} 400 \\ 600 \\ 500 \\ 350 \\ \vdots \end{pmatrix}$$

utdanning erfaring lønn

$m \times 2$ matrise

vektor med m komponenter

Tensorflow

- Optimalisert for beregning av matriser og vektorer.
- Når data lagres i vektor/matriseformat, muliggjør det parallellbehandling.
  - ↳ flere operasjoner kan skje simultant, og utnytte GPU/CPU til maskinen.

Tensor

„En "vektor"/array av tall som er plassert i en grid med variabelt antall akser!"

① Skalar (rank-0 tensor)

- Tallet 3, 4.5, 79, ..., osv
- I matematikken: kun en størrelse, ikke en retning.

$\mathbb{R}$

② Vektor (rank-1 tensor)

- Har størrelse og retning

$$\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}$$

$\mathbb{R}^n$

Vi vil bruke dette mye! 3dimensjonale vektorer kan visualiseres:

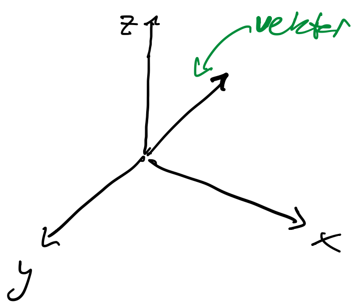

③ Matrise (rank-2 tensor)

- Består av rader og kolonner.
- I ML representerer matriser ofte dataen vår. Som feks.:

$$X = \begin{pmatrix} 3 & 4 & 8 \\ 2 & 6 & 9 \\ 1 & -2 & 15 \end{pmatrix}$$

$\mathbb{R}^{n \times m}$

④ Rank-3 tensor

- Som en kube (matriser "oppå hverandre")

$$\begin{bmatrix} 3 & 5 & 7 \\ 2 & 6 & 1 \\ 8 & 4 & 9 \end{bmatrix} \begin{bmatrix} 4 & 2 & 6 \\ 8 & 5 & 9 \\ 8 & 4 & 9 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 2 \\ 8 & 9 & 6 \end{bmatrix}$$

$\mathbb{R}^n + \mathbb{R}^m + \mathbb{R}^p$

RGB = fargebilder

↳ Består av tre matriser.

- ↳ En rød matrise
- ↳ En grønn matrise
- ↳ En blå matrise

} Sammen lager de fargebilder.

Normer

Viktig konsept fra lineær algebra

Normen til en vektor $\mathbf{x}$ er en måling av dens lengde.

Generelle normer er definert:

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}$$

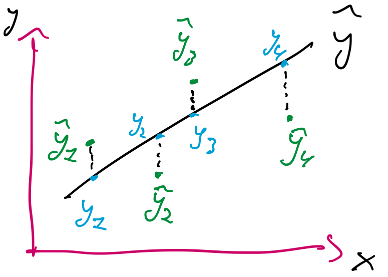

$\hat{y}_i$ = predikert verdi av y_i

$r = y_i - \hat{y}_i$ (residual)

Eks: L1-normen

$$\|\mathbf{x}\|_1 = \sum_{i}^{n} |x_i|$$

Eks: L2-normen

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i}^{n} x_i^2}$$

L2-normen relaterer til MSE

$$\boxed{r = y_i - \hat{y}_i}, \quad \boxed{MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 = \frac{1}{n} \|\mathbf{r}\|_2^2}$$

residual-vektoren.

Oppgave: Vis hvorfor ?

- Normer brukes til optimalisering for å evaluere og minimere tap. Mer om dette senere!

Nødvendig kalkulus

Derivasjon

$$f'(x) = \lim_{h \to 0} \frac{f(x+h) - f(x)}{h}$$

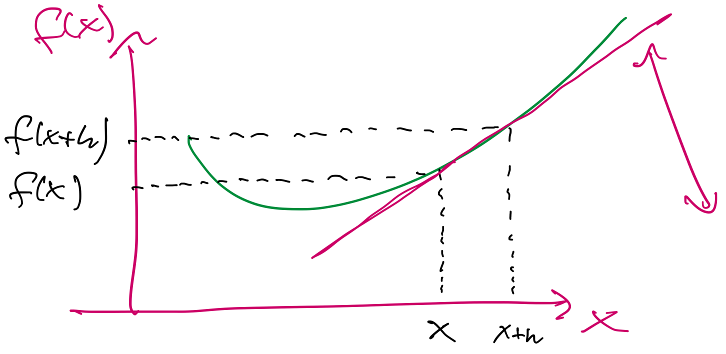

Brukes til å finne stigningstallet til tangenten til funksjonen f(x) i punktet x.

Da kan vi finne hvor funksjonen er brattest, går vi andre veien, finner vi hvor funksjonen minker mest.

↳ Dette kaller vi en tapsfunksjon / kostfunksjon.

↳ Dette er kjernen i mye av maskinlæring!

Nødvendig statistikk

Hvis X er en stokastisk variabel med sannsynlighetsfordeling f(x).

	X er diskret	X er kont.
Forventningsverdi	$E[X]=\sum_x x\cdot f(x)$	$E[X]=\int_{-\infty}^{\infty} x\cdot f(x)\,dx$
Varians	$\sigma^2=E[(X-\mu)^2]$ $=\sum_x (x-\mu)^2\cdot f(x)$	$\sigma^2=E[(X-\mu)^2]$ $=\int_{-\infty}^{\infty}(x-\mu)^2\cdot f(x)\,dx$

Vi har observert response Y og prediktert respons $\hat{Y}$

$$Y=f(X)+\varepsilon\ , \qquad \hat{Y}=\hat{f}(X)$$

Irreducible & reducible error

$$E[(Y-\hat{Y})^2]=E\left[\left(f(X)+\varepsilon-\hat{f}(X)\right)^2\right]$$

$$=E\left[\left(f(x)+\varepsilon-\hat{f}(x)\right)\left(f(x)+\varepsilon-\hat{f}(x)\right)\right]$$

Vi bruker at forventningsverdien er lineær:

$$E\left[\sum_i^n X_i\right] = \sum_i^n E[X_i]$$

- Vi bruker at forventningsverdien til $f(x)$ og $\hat{f}(x)$ er konstant.
- Antar $\varepsilon \sim N(0, \sigma^2)$

$$\Rightarrow E[\varepsilon] = 0, \quad E[\varepsilon^2] = Var(\varepsilon)$$

Til slutt, etter en del regning, får vi

$$E[(Y-\hat{Y})^2] = \underbrace{[f(x) - \hat{f}(x)]^2}_{\substack{\text{reducible error} \\ \text{(forklarbar feil)}}} + \underbrace{Var(\varepsilon)}_{\substack{\text{Irreducible error} \\ \text{(ikke-forklarbar feil)}}}$$

- Reducible error kan vi gjøre noe med!
  - ↳ Bedre modell
  - ↳ Bedre data
  - ↳ optimaliseringsalgoritmer
- Irreducible error kan vi ikke gjøre noe med!
  - ↳ verden er kaotisk
  - ↳ Alltid finnes støy!

Regresjon versus klassifikasjon

- Kontinuerlig output variabel

"Hva er temp. imorgen?"

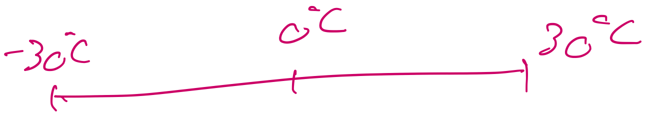

Hva er aksjekursen imorgen?

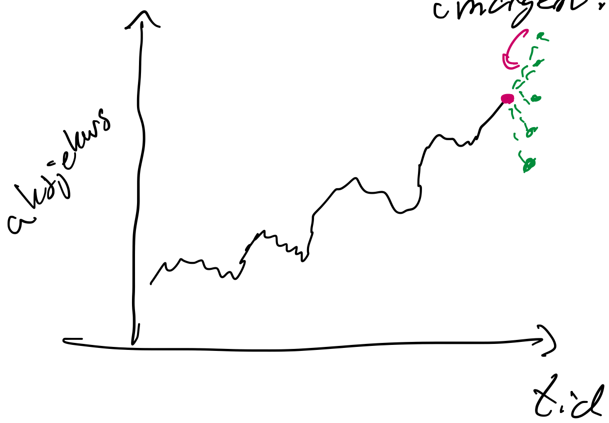

- Kategorisk output variabel

"Er det kaldt eller varmt imorgen?"

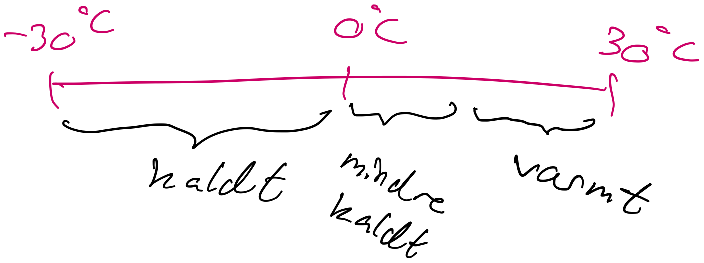

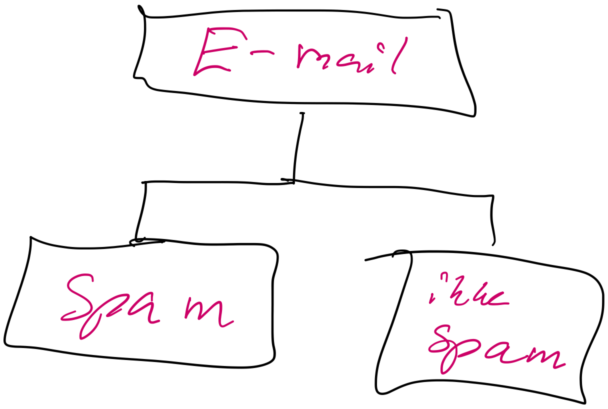

Prediksjon versus inferens

- Viktig tema i ML og statistikk

Vi ser et eksempel med lineær regresjon.

- Kvantitativ respons Y

kalles også output, målvariabel, target, avhengig variabel

- p ulike prediktorer

$$X=(X_1, X_2, \dots, X_p)$$

kalles også uavhengig variabel, forklarende -"-, input, kovariater, features

Her vil typisk X være en matrise, og Y en vektor med responsene.

Hvis vi skal se på multippel lineær regresjon, er sammenhengen (antatt) å være lineær mellom Y og X.

$$Y = \underset{\text{ukjent funksjon}}{f}(\underset{\text{våre features}}{X}) + \underset{\varepsilon \sim N(0, \sigma^2)}{\varepsilon}$$

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p + \varepsilon$$

Vi lager vår modell:

$$\hat{Y} = \hat{f}(X)$$

$$= \hat{\beta}_0 + \hat{\beta}_1 X_1 + \dots + \hat{\beta}_p X_p \quad ! \; \boxed{E[\varepsilon] = 0} \; !$$

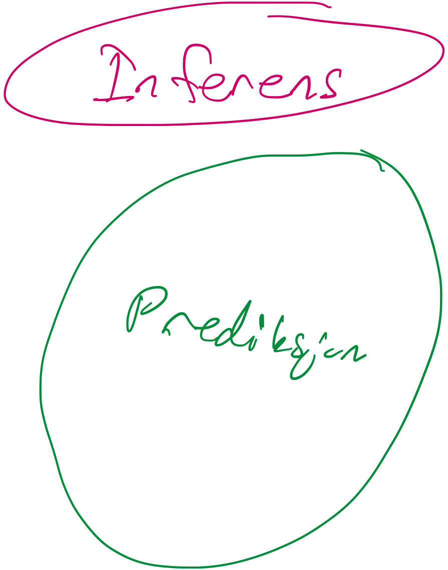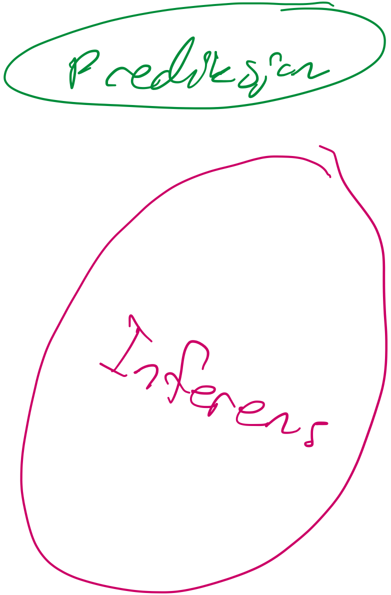Prediksjon	Inferens
- Prosessen å forutsi fremtidige utfall basert på tilgjengelige data. $\hat{Y} = \underset{\text{black box}}{\hat{f}}(X)$	- Fokuseres på å trekke konklusjoner om egenskapene til en underliggende sannsynlighetsfordeling. - Finne relasjon mellom koeffisientene (β_i) og output. - Fokuseres på konfidensintervall, hypotese-testing, p-verdier...
Maskinlæring	Statistikk